

Machine Learning e Visão Computacional [T1]

Situação de Aprendizagem (Projeto Avaliativo) - Módulo 1 - Semana 14

SUMÁRIO

1 CONTEXTUALIZAÇÃO	1
2 DESAFIO	2
3 RESULTADOS ESPERADOS (ENTREGA)	2
4 REQUISITOS DA APLICAÇÃO	3
Fase 1: Análise Exploratória de Dados (EDA)	3
Fase 2: Tratamento e Limpeza (Data Prep)	3
Fase 3: Feature Engineering (Coluna Calculada)	3
Fase 4: Separação, Balanceamento e Escalonamento Seguro	3
Fase 5: Modelagem e Validação (O Desafio do Overfitting)	4
Fase 6: Avaliação e Veredito de Negócios	4
5 ROTEIRO DA APLICAÇÃO	4
5.1 DOCUMENTAÇÃO NO README.MD	4
5.2 USO DO GITHUB	5
5.3 GRAVAÇÃO DE VÍDEO	5
6 CRITÉRIOS DE AVALIAÇÃO	5
7 PLANO DE PROJETO	7

1 CONTEXTUALIZAÇÃO

No cenário atual do mercado de tecnologia, dados brutos são apenas um potencial adormecido. Para que uma Inteligência Artificial gere valor real, o profissional de Ciência de Dados precisa dominar o processo de ETL (Extração, Transformação e Carga) e a Análise Exploratória. Se injetarmos dados sujos, duplicados ou desbalanceados em um algoritmo preditivo, enfrentaremos o clássico problema do Garbage In, Garbage Out (Lixo Entra, Lixo Sai), gerando modelos "viciados" ou instáveis, que apresentam métricas falsamente otimistas durante o desenvolvimento, mas que falham criticamente ao lidar com novos clientes ou cenários de mercado. Consequentemente, são geradas previsões incorretas que podem se traduzir em grandes prejuízos financeiros, automações perigosas e perda de credibilidade para a empresa.

Neste trabalho final, você colocará em prática todo o rigor metodológico de um Cientista de Dados: desde a limpeza estatística e criação de novas variáveis lógicas (Feature Engineering), até a experimentação, o controle de hiperparâmetros para evitar o overfitting e a otimização de algoritmos clássicos de Machine Learning (KNN e Árvores de Decisão), culminando em uma recomendação de negócios baseada na análise das falhas do modelo.

2 DESAFIO

Você deverá atuar como um Cientista de Dados corporativo e construir um Pipeline Preditivo completo. Para isso, escolha **UMA** das duas bases de dados abaixo para resolver um problema real de mercado:

OPÇÃO A: Risco de Crédito (Setor Financeiro)

- **O Problema:** Um banco precisa prever se um cliente se tornará inadimplente (alvo: loan_status = 1) ou se pagará o empréstimo em dia (alvo: loan_status = 0).
- **Desafio de Negócio:** Qual o impacto financeiro para o banco se a máquina classificar um bom pagador como "Risco de Calote" (Falso Positivo) ou um mau pagador como "Seguro" (Falso Negativo)?
- **Base(.csv):**
https://drive.google.com/file/d/1R4WCMc_56lv3fMaDalUBAz5jSxeZOcwl/view?usp=sharing

OPÇÃO B: E-commerce Churn (Setor de Varejo)

- **O Problema:** Um aplicativo de vendas precisa prever quais clientes estão prestes a abandonar a plataforma (alvo: Churn = 1) para oferecer cupons preventivos de retenção.
- **Desafio de Negócio:** O que custa mais caro para o aplicativo: dar um cupom de desconto para quem já ia continuar comprando normalmente (Falso Positivo) ou perder um cliente em definitivo sem tentar retê-lo (Falso Negativo)?
- **Base(.csv):**
<https://drive.google.com/file/d/1Gcdv7zg4BDquToRBdRwIDksHicJPO0dd/view?usp=sharing>

3 RESULTADOS ESPERADOS (ENTREGA)

O desenvolvimento deverá ser registrado nas seguintes plataformas:

- **GitHub:** Repositório público contendo o código-fonte (notebook .ipynb ou arquivo .py) e o arquivo descritivo README.md.
- **Plataforma de Vídeo (Google Drive / YouTube):** Link de um vídeo de apresentação gravado e configurado em modo de visualização público (modo leitor).

Os dois links (GitHub e Vídeo) deverão ser postados na tarefa **Módulo 1 - Projeto Avaliativo** dentro do AVA **na semana 13** até a data limite estipulada.

Data da entrega: 17/07/2026 às 22h

Atenção: Não serão aceitos projetos submetidos após a data limite da atividade ou alterados após a entrega. Será considerado como data final de entrega o timestamp da última

modificação (commit) no repositório do GitHub. Os links não submetidos no AVA receberão nota zero.

4 REQUISITOS DA APLICAÇÃO

Seu código deve ser estruturado de forma clara, dividido explicitamente nas fases técnicas abaixo. **Decisões tomadas no código sem justificativa textual (em células Markdown ou comentários) sofrerão severa penalização na nota.**

Fase 1: Análise Exploratória de Dados (EDA)

- **Descritiva e Estatística:** Exiba explicitamente o tamanho total da base (linhas e colunas), os tipos de dados de cada variável e o sumário estatístico descritivo (médias, mínimos, máximos e quartis via `.describe()`) e etc.
- **Visual:** Plote no mínimo 3 gráficos explicativos (ex: histograma de distribuição de idades/valores, gráfico de barras provando o desbalanceamento da variável alvo e um mapa de calor de correlação de Pearson).
- **Tomada de Decisão:** Escreva um parágrafo analítico interpretando o que a estatística e os gráficos revelaram sobre os dados e como isso guiará sua estratégia de preparação.

Fase 2: Tratamento e Limpeza (Data Prep)

- **Duplicadas:** Identifique e remova linhas duplicadas que geram redundância.
- **Valores Nulos:** Identifique as colunas com dados ausentes. É obrigatório justificar textualmente a escolha da técnica de imputação: usou a Média (indicada para distribuições normais/simétricas) ou a Mediana (indicada para mitigar o impacto de outliers)?
- **Tratamento de Outliers:** Identifique a presença de valores discrepantes na base (ex: via *boxplots*). O aluno deve tomar uma decisão fundamentada de tratamento (remoção, clipping ou manutenção). *Nota pedagógica:* Avalie o impacto disso nos modelos, lembrando que o KNN é extremamente sensível a outliers (muda as distâncias euclidianas), enquanto a Árvore de Decisão é robusta a eles.

Fase 3: Feature Engineering (Coluna Calculada)

Você deve criar obrigatoriamente uma nova coluna numérica combinando variáveis existentes por meio de operadores matemáticos. Atenção: Trate os nulos das colunas originais *antes* do cálculo para evitar contaminação por valores NaN ou infinitos.

- **No caso de escolha da Base A (Crédito):** crie a coluna `comprometimento_renda = (loan_amnt / person_income) * 100`.
- **No caso de escolha da Base B (E-commerce):** crie a coluna `cashback_por_pedido = CashbackAmount / OrderCount`.

Fase 4: Separação, Balanceamento e Escalonamento Seguro

- **Encoding:** converta colunas textuais/categóricas em formato numérico utilizando técnicas adequadas (como *One-Hot Encoding* ou *Label Encoding*).

- **Split de Dados:** Separe as variáveis preditoras (X) do alvo (y) e divida em Treino e Teste (`test_size=0.20`), aplicando o parâmetro `stratify=y` para preservar a proporção das classes.
- **Balanceamento de Classes:** como ambas as bases são desbalanceadas, aplique uma técnica de reamostragem (ex: SMOTE ou Random Under Sampling). Regra de Ouro: o balanceamento deve ser aplicado *estritamente e apenas* nos dados de Treino para evitar o vazamento de dados.
- **Escalonamento Seguro:** aplique o `StandardScaler` exclusivamente nas variáveis contínuas destinadas ao modelo KNN (`fit_transform` no treino balanceado e `transform` no teste). Demonstre no código que o modelo de Árvore de Decisão foi treinado sem a necessidade de escalonamento, justificando que o algoritmo de árvore realiza cortes monotônicos independentes de escala.

Fase 5: Modelagem e Validação (O Desafio do Overfitting)

Você deve realizar múltiplos testes alterando os hiperparâmetros de complexidade e comparar os resultados tanto na base de Treino quanto na base de Teste para diagnosticar o *overfitting*.

- **Otimização do KNN:** Varie o parâmetro `n_neighbors` (K) testando no mínimo 4 valores distintos (ex: K = 3, 5, 7 e 9).
- **Otimização da Árvore:** Varie o parâmetro `max_depth` (profundidade máxima) testando no mínimo 4 cenários (ex: profundidades 3, 5, 7 e ilimitada/None).
- **Diagnóstico de Overfitting:** Demonstre em tabelas ou gráficos que você monitorou as métricas em ambas as bases. Explique qual configuração evitou que o modelo apenas "decorasse" os dados de treino (overfitting) e qual garantiu a melhor capacidade de generalização no teste.

Fase 6: Avaliação e Veredito de Negócios

Para as duas melhores configurações selecionadas na fase anterior (a melhor árvore vs o melhor KNN):

- Imprima o relatório completo de classificação (*Classification Report*) e plote graficamente as Matrizes de Confusão.
- **Análise de Negócio:** Conecte a estatística à realidade financeira do setor escolhido. Explique qual erro (Falso Positivo ou Falso Negativo) gera o pior impacto financeiro/operacional e dê o seu veredito final justificando qual dos dois modelos você colocaria em produção.

5 ROTEIRO DA APLICAÇÃO

5.1 DOCUMENTAÇÃO NO README.MD

O repositório do GitHub deve conter um arquivo markdown bem estruturado com:

- Descrição clara do problema de negócio.
- Resumo executivo contendo os principais insights da EDA e o veredito do melhor modelo.

5.2 USO DO GITHUB

- O desenvolvimento não deve ocorrer em um único commit massivo. É indicado criar ramificações (*branches*) separadas para as etapas do projeto (ex: *fase/eda*, *fase/data-prep*, *fase/modelagem*).
- Utilize boas práticas de Commits Semânticos (ex: *feat: adiciona tratamento de nulos*, *fix: corrige divisao por zero*).

5.3 GRAVAÇÃO DE VÍDEO

Grave uma apresentação técnica de até 7 minutos compartilhando a tela do seu código, respondendo objetivamente:

1. Qual base de dados foi escolhida e qual o objetivo de negócio do modelo?
2. Quais insights visuais e estatísticos mudaram sua visão na Análise Exploratória (EDA)?
3. Como você tratou os nulos e os outliers, considerando os impactos específicos no KNN e na Árvore?
4. Como você identificou e evitou a ocorrência de *overfitting* ao mudar os parâmetros do KNN (*K*) e da Árvore (*max_depth*)?
5. Olhando para a Matriz de Confusão, qual modelo você recomenda para a diretoria da empresa e por quê?

6 CRITÉRIOS DE AVALIAÇÃO

A tabela abaixo apresenta os critérios que serão avaliados durante a correção do projeto. O mesmo possui variação de nota de 0 (zero) a 10 (dez) como nota mínima e máxima, e possui peso de 60% sobre a avaliação do módulo.

Serão desconsiderados e atribuída a nota 0 (zero) os projetos que apresentarem plágio de soluções encontradas na internet ou de outros colegas. Lembre-se: Você está livre para utilizar outras soluções como base, mas não é permitida a cópia.

Apresentação do Projeto				
Nº	Critério de Avaliação	0	0,5	1,0
1	Apresentação e Didática	NÃO REALIZADO. Gravou o vídeo demonstrando domínio técnico, respondeu aos 5 tópicos do item 5.3 e explicou o código com clareza dentro do tempo limite.	PARCIALMENTE. Gravou o vídeo demonstrando domínio técnico, respondeu aos 5 tópicos do item 5.3 e explicou o código com clareza dentro do tempo limite.	TOTALMENTE. Gravou o vídeo demonstrando domínio técnico, respondeu aos 5 tópicos do item 5.3 e explicou o código com clareza dentro do tempo limite.

Uso adequado do GitHub e Readme.md				
Nº	Critério de Avaliação	0	0,5	1,0

2	Versionamento e Git	NÃO REALIZADO. Código estruturado via branches com commits incrementais frequentes e mensagens claras. Não trabalhou direto na main.	PARCIALMENTE. Código estruturado via branches com commits incrementais frequentes e mensagens claras. Não trabalhou direto na main.	TOTALMENTE. Código estruturado via branches com commits incrementais frequentes e mensagens claras. Não trabalhou direto na main.
3	Documentação Técnica	NÃO REALIZADO. Arquivo README.md completo contendo contexto, dicionário de dados atualizado com a nova coluna e resumo executivo para a diretoria.	PARCIALMENTE. Arquivo README.md completo contendo contexto, dicionário de dados atualizado com a nova coluna e resumo executivo para a diretoria.	TOTALMENTE. Arquivo README.md completo contendo contexto, dicionário de dados atualizado com a nova coluna e resumo executivo para a diretoria.

Desenvolvimento adequado da Aplicação

Nº	Critério de Avaliação	0	0,5	1,0
4	EDA & Tratamento de Dados	NÃO REALIZADO. Executou análises descritivas/visuais completas. Tratou nulos e duplicados com justificativas estatísticas válidas e tomou decisão correta sobre outliers.	PARCIALMENTE. Executou análises descritivas/visuais completas. Tratou nulos e duplicados com justificativas estatísticas válidas e tomou decisão correta sobre outliers.	TOTALMENTE. Executou análises descritivas/visuais completas. Tratou nulos e duplicados com justificativas estatísticas válidas e tomou decisão correta sobre outliers.
5	Engenharia e Preparação	NÃO REALIZADO. Criou a coluna calculada sem erros lógicos. Realizou o split estratificado e aplicou o balanceamento sem causar vazamento de dados (Data Leakage).	PARCIALMENTE. Criou a coluna calculada sem erros lógicos. Realizou o split estratificado e aplicou o balanceamento sem causar vazamento de dados (Data Leakage).	TOTALMENTE. Criou a coluna calculada sem erros lógicos. Realizou o split estratificado e aplicou o balanceamento sem causar vazamento de dados (Data Leakage).
6	Escalonamento e Balanceamento	NÃO REALIZADO. Aplicou o escalonamento numérico apenas no modelo KNN, provando entender que as Árvores de Decisão dispensam essa etapa.	PARCIALMENTE. Aplicou o escalonamento numérico apenas no modelo KNN, provando entender que as Árvores de Decisão dispensam essa etapa.	TOTALMENTE. Aplicou o escalonamento numérico apenas no modelo KNN, provando entender que as Árvores de Decisão dispensam essa etapa.
7	Otimização e Parâmetros	NÃO REALIZADO. Avaliou pelo menos 4 valores de K e 4 valores de max_depth, comparando os resultados na base de Treino e Teste simultaneamente.	PARCIALMENTE. Avaliou pelo menos 4 valores de K e 4 valores de max_depth, comparando os resultados na base de Treino e Teste simultaneamente.	TOTALMENTE. Avaliou pelo menos 4 valores de K e 4 valores de max_depth, comparando os resultados na base de Treino e Teste simultaneamente.

8	Combate ao Overfitting	NÃO REALIZADO. Diagnosticou de forma analítica os pontos em que os modelos começaram a sofrer overfitting, escolhendo o parâmetro ideal de equilíbrio.	PARCIALMENTE. Diagnosticou de forma analítica os pontos em que os modelos começaram a sofrer overfitting, escolhendo o parâmetro ideal de equilíbrio.	TOTALMENTE. Diagnosticou de forma analítica os pontos em que os modelos começaram a sofrer overfitting, escolhendo o parâmetro ideal de equilíbrio.
9	Análise de Erros e Matriz	NÃO REALIZADO. Gerou os relatórios de métricas e interpretou corretamente as matrizes de confusão sob a ótica dos Falsos Positivos e Falsos Negativos.	PARCIALMENTE. Gerou os relatórios de métricas e interpretou corretamente as matrizes de confusão sob a ótica dos Falsos Positivos e Falsos Negativos.	TOTALMENTE. Gerou os relatórios de métricas e interpretou corretamente as matrizes de confusão sob a ótica dos Falsos Positivos e Falsos Negativos.
10	Veredito de Negócios	NÃO REALIZADO. Conectou o resultado matemático à dor financeira real da empresa, justificando com solidez qual modelo deve ser colocado em produção.	PARCIALMENTE. Conectou o resultado matemático à dor financeira real da empresa, justificando com solidez qual modelo deve ser colocado em produção.	TOTALMENTE. Conectou o resultado matemático à dor financeira real da empresa, justificando com solidez qual modelo deve ser colocado em produção.

7 PLANO DE PROJETO

Ao construir a aplicação proposta nesta Situação de Aprendizagem, o estudante consolidará habilidades fundamentais exigidas pelo mercado de trabalho moderno, aprendendo a:

- Cooperar e gerenciar projetos de código utilizando Git e GitHub de maneira profissional, entendendo o impacto de ramificações e do histórico de modificações no ciclo de desenvolvimento.
- Executar pipelines complexos de engenharia de dados em Python, compreendendo as armadilhas clássicas como vazamento de dados e assimetria estatística.
- Desenvolver raciocínio crítico em Inteligência Artificial, compreendendo que a escolha de um algoritmo não se baseia apenas em números frios de acurácia, mas sim no alinhamento estratégico entre as falhas do modelo (matriz de confusão) e a saúde financeira e operacional do negócio.